

【专栏二：深度学习10】 - 【一张图讲清楚：为什么既要 做数据归一化?又要划分 Train / Val / Test? 】



快乐飞猪ing



· 码龄7年 · 粉丝可见 · 编辑



墨衍会员 · AI 创作全网分发

原创 · 2026-03-30 00:37:47 · 478 阅读



AI 写同款 · AI 选题



手把手教你安装和使用 Labellmg 工具进行目标检测数据标注，并导出为 YOLO 格式的 txt ...

[阅读详情 >](#)

本文介绍了YOLOv11模型训练中的数据标注关键点。首先强调了数据质量对模型性能的决定性作用，...

很多人刚开始训练模型时，会犯两个非常典型的错误：

- 直接把原始数据丢进去训练
- 用同一份数据既训练又评估

结果就是：

- 模型训练不稳定
- 评估结果不可信


但他们往往不知道问题出在哪。

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060



这张图其实在讲一个完整流程：

• 原始数据 → 数据归一化 → 数据划分 → 训练 → 验证 → 测试

你只要顺着这条线看，就能理解：

👉 为什么既要“处理数据”，又要“划分数据”

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

一、第一步：为什么要做数据归一化 (左半部分)

先看图的左侧。

你会发现一个问题：

- 有的特征范围是 0~1000
- 有的特征只有 0~1

👉 这就是：特征尺度不一致

1.会带来什么问题？

模型在训练时，本质是在做加权计算：

$$y = w_1x_1 + w_2x_2 + \dots$$

如果：

- x_1 很大 (比如 1000)
- x_2 很小 (比如 0.1)

那么模型更容易被“大数值特征”主导。

👉 结果就是：

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

- 小特征被忽略
- 学习不公平
- 训练过程不稳定

2.从优化角度看（关键理解）

你可以把训练想象成：

👉 在“山谷”里找最低点（梯度下降）

- 未归一化：山谷又窄又扁 → 走得歪、来回震荡
- 归一化后：山谷更圆 → 更容易找到方向

👉 这就是图左边在表达的核心：

归一化 = 统一尺度，让模型更容易学习

3.怎么做归一化？

最常见的方法是**标准化** Q ：

$$x' = \frac{x - \mu}{\sigma}$$

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

简单理解：

- 减去平均值
- 再除以标准差

👉 让所有特征处于相似范围，左半部分总结一句：

归一化的本质，是让模型“学得更顺”

二、第二步：为什么要划分 Train / Val / Test (右半部分)

再看图右侧。这里在讲另一件完全不同但同样重要的事：**如何正确评估模型**

为什么不能用同一份数据训练和评估？看图里的类 Q 比：“**背过的题 vs 真考试**”

如果你：

- 用同一份数据训练
- 再用这份数据评估

那就相当于：**考前把答案背了一遍，再去做同一张试卷**，结果当然很好，但没有任何意义。

正确做法：**三份数据**，图中已经帮你拆好了：

1 Train (训练集)

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

- 学参数
- 不断优化模型

2 Validation (验证集)

- 调整模型 (学习率、结构等)
- 判断是否过拟合

对应你之前学的: `val_loss` 上升 = 开始过拟合

3 Test (测试集)

- 最终评估模型

最关键的一点 (必须记住): **Test 集只在最后用一次, 不参与训练和调参**

这一部分的本质

数据划分, 是为了让评估“可信”

三、把两件事串起来 (这才是这篇的重点)

现在你可以把整张图串起来看:

左边在解决什么?

内容来源: [csdn.net](https://blog.csdn.net/m0_46279060)

作者昵称: 快乐飞猪ing

原文链接: https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页: https://blog.csdn.net/m0_46279060

👉 数据归一化：让模型更容易学（训练问题）

右边在解决什么？

👉 数据划分：让结果更可信（评估问题）

两者本质不同，但缺一不可：

- 只做归一化，不划分数据 → 评估会骗人
- 只划分数据，不归一化 → 模型学得很痛苦

一句话总结整张图：

归一化让模型学得顺，数据划分让结果更可信

四、最容易踩的两个坑（帮你补全认知）

1.坑1：用全部数据做归一化

很多人会这样做：

- 用全部数据算均值和方差
- 再做归一化

这是不对的

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

正确做法是：只用训练集计算归一化参数，再应用到 Val/Test

否则就会：数据泄露 (Data Leakage)

2.坑2：反复用 Test 调模型

如果你：

- 一边看 Test 结果
- 一边调模型

那么：Test 就不再是“真正没见过的数据”，评估就失去意义了

五、最后总结

你只需要记住这三点：

- 1 数据归一化：解决“模型好不好学”
- 2 数据划分：解决“评估准不准”
- 3 两者都是训练前必须做的准备工作

最核心一句：

一个影响训练效率，一个决定评估可信度

内容来源：csdn.net

作者昵称：快乐飞猪ing

原文链接：https://blog.csdn.net/m0_46279060/article/details/159613314

作者主页：https://blog.csdn.net/m0_46279060

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

CSDN

内容来源: csdn.net
作者昵称: 快乐飞猪ing
原文链接: https://blog.csdn.net/m0_46279060/article/details/159613314
作者主页: https://blog.csdn.net/m0_46279060